

Deal With the Problem

1. 資料擷取

一開始使用了所有數據進行模型訓練，成效一直不彰。發現依照現實背景有極大可能對模型造成影響：2013 年至 2016 年的資料包含了許多雜訊資料（例如發生大地震）。因此在後來幾次模型訓練的程式碼，嘗試將此段資料刪去，僅保留 2017-01-01 之後的數據來進行處理。

2. 油價處理

除了基礎的向前或向後補值，還加入七天移動平均線 (7-day MA)，有助於模型看出油價短期的趨勢走向。

3. 時間特徵

將日期拆成年、月、日、星期，並且加入一項 DayOfYear（表示一年中的第幾天），使模型有時間流動的季節感。

4. 發薪日特徵

設計一個 is_payday 特徵，因為 15 日或月底（發薪日）通常是民眾消費能力最高的時候。

Model Choice and Variables Changes

1. 模型轉換：將原本的 LinearRegression 模型，改成為 XGBRegressor 模型。

a. 用 LinearRegression 比擬現實生活過於單純

線性回歸的假設是一條直線的比例關係，在此作業中代表了特徵及銷售量的線性關係。然而在現實生活中，商店的銷售樣貌並非能以單純線性圖形來表現的。

舉例而言，假設一個商品平日的銷售量是 100 個，但是到了假日的銷售量不一定是 200 個。而若遇到其他因素，如周末、發薪日、促銷等等，銷售量可能出現非線性疊加。

因此若使用單純的 LinearRegression 模型，可能無法掌握這種交互作用。

b. XGBRegressor 的優勢

XGBoost 的基礎是樹狀模型，是以決策樹組成的。其特徵是擅長處理條件判斷（非線性關係）的問題。

如果今天是周末，並且剛好遇到發薪日，又遇上商品促銷活動的複雜條件，此模型能夠掌握到這種外界影響因素較多的資料，並判斷其為非線性趨勢，對於預測真實狀況的銷售數據（Time Series Forecasting）來說，結果比線性回歸模型來的準確很多。

2. 對銷售量做 log1p 及 expm1、負數歸零

a. 評分標準 RMSLE

Kaggle 算分方式是依 RMSLE 公式以進行後面計算。根據講義提供的公式，在計算誤差前，它會先對程式跑出來的預測值和真實值取 $\log$ 。

然而，XGBoost 模型是設計用來最小化一般誤差 (RMSE) 的。為了解決這個誤差，在將資料提供給模型訓練之前，先對目標值取對數，在模型優化 RMSE 的時候，便是等同於在優化 Kaggle 要求的 RMSLE，在此稱作 Target Transformation。

b. 銷售量分布極端

商店的銷售量通常是長尾分布：大部分時候賣出的量少，但遇到節日時數量可能暴增，此種極端情形可能會使模型被影響。取 $\log(\log p)$ ：表示取 $\log(y+1)$ 可以把那些極端數值壓縮，使數據分布變得較對稱（接近常態分布），模型能學得更穩定。

c. 預測完成後的還原 ($\exp m1$) 與負數歸零

- i. 還原：由於訓練時丟給模型的是被 $\log$ 壓縮過的數值，因此預測出來的結果也會是 $\log$ 值。此時需使用 $\log p$ 的反函數 $\exp m1 (e^x - 1)$ ，把數字調回原本真實的銷售量，再上傳到 Kaggle 進行評分。
- ii. 歸零：機器學習模型在進行計算時，可能會產生微小的負數（如可能預測出 -0.5 個商品）。但在現實中，銷售量只會大於或等於 0。此外，因為 $\log$ 不能算負數，因此當 RMSLE 遇到負數時可能無法跑出結果，因此在最後將負數歸零能避免此項失誤。

Ablation Study

1. 資料長度比較

- a. 原本以為資料越多，模型的學習結果越好，因此使用了 2013 到 2017 的所有資料進行模型訓練。
- b. 經濟環境的改變與自然災害會造成模型收到太多雜訊，且過久之前的資料與現在的消費習慣也有差異，因此加入 `train=train[train['date']>='2017-01-01']`，只使用 2017 的數據進行模型訓練。從結果來看，刪去多於資料確實對於模型誤差有顯著幫助。同時能得知在時間序列的預測中，比起資料數量，資料的時效性更為重要。

2. 特徵過度擬合

- a. 為了幫助資料處理模型更快找到規律，一開始把商店編號 (`store_nbr`) 與商品類別 (`family`) 合併成一個全新的特徵，但分數卻退步了。
- b. 此為 `overfitting` 現象。當特徵被切得太具體時，模型把訓練集裡面的特例都背了下來，失去 `generalization` 的能力。此時，模型只要遇到微小的變化就會將誤差拉得更大。

- c. 在成績最好的訓練模型裡捨去這個組合特徵，用最基礎的特徵讓模型掌握趨勢。

3. 模型參數調整

- a. 調整 2017 年的資料及基礎特徵後，試著利用 XGBoost 參數的調整降低分數。
- b. 調整方式
 - i. 限制樹的深度 (max_depth)：為了避免過多複雜、會影響模型學習的資訊，刻意將 max_depth 的參數控制在 9-11 之間，以防出現過度擬合的情況。
 - ii. 調高子節點的最小權重 (min_child_weight)：把此項數值調高，避免模型只讀取了極少或極端資訊就將其作為數據趨勢的一部分。

舉例而言，假設今天某店店長（模型）在考慮推出一項新品 A：

Situation A（參數=1）

今天只有一個顧客來說希望嘗試 A，而店長便立刻認為 A 品項一定會大受歡迎，接著花了大筆經費買了大量食材，但是到了隔天發現沒有人買單，整批材料便全部報廢虧錢了。

此情況在模型的訓練中，就是因為模型太衝動學習，把少數的特例當作大趨勢，死背了這些雜訊，造成 Overfitting。

Situation B（參數=10）

下了命令提醒店長，除非累積了 10 個顧客詢問新品 A，否則將不會推出此品項。因此若詢問的人數過少，店長便會拒絕推出新品。

此情況代表，若可依賴數據不夠多，就不能做決定（不允許長出新的決策分支）。

- iii. 學習率與樹的數量 (learning_rate & n_estimators)：為了找到誤差的最低點，把學習率降低並且增加樹的數量，可以讓模型有足夠時間達到最佳解。