



Kaggle Case Study

Isolated Sign Language Recognition

工工27 陳暄承 林彥妤 倪歆絜



發生什麼事！！



很多聽障兒童的父母本身聽得見，但不會手語，所以小孩在小時候可能沒有足夠的語言溝通環境，就有機會產生語言剝奪症，影響學習、社交、就業等發展。

資料集總共有約 10^6 萬支手語影片，由 21 位聾人手語者表演。比賽目標是從中**辨識出250種不同的美國手語 (ASL) 單字**，建立一個手語辨識模型，放進學習 App —— PopSign 中，讓父母可以透過遊戲學習，並且自己比手語讓 App 判斷是否正確。



資料是什麼？！

●●●●●

原始資料為手語影片，但比賽直接提供已經處理好的人體關鍵點座標資料
一段手語會變成多個時間點(幀)，每個時間點包含543個人體關鍵點

類型	數量
臉	468
左手	21
右手	21
身體姿勢	33

每個人體關鍵點有座標 (x, y, z) 代表當時人體關鍵點在空間中的位置資訊

●●●●●

觀世Input啥



輸入一段手語影片裡543個人體關鍵點各自在每一幀的座標
例如：

第 1 幀

類別	人體關鍵點	x	y	z
臉	鼻子	0.50	0.30	-0.02
左手	左手食指尖	0.40	0.60	-0.10

第 2 幀

類別	人體關鍵點	x	y	z
臉	鼻子	0.50	0.30	-0.02
左手	左手食指尖	0.45	0.55	-0.08



Output啥



模型輸出 250 個手語單字的機率

例如：

類別	機率
TV	0.01
after	0.02
aurplane	0.03
apple	0.85
Other 246 Classes	0.09

最後取機率最高的類別作為預測結果



怎評？！



準確率 = 預測正確的影片數 / 全部影片數

測試集約 40,000 支影片，若模型預測正確 34,000 支

準確率 = $34,000 / 40,000 = 0.85$

→ 表示模型有 85% 的影片分類正確率



來看別人怎麼贏！

1. 特徵工程與資料前處理

- 只挑關鍵點
- 調整視角，以鼻子為世界中心
- 靜態圖中加入動態/速度特徵



2. 模型架構：1D CNN 與 Transformer 的完美結合

若只使用單一Transformer模型效果太差，於是選擇結合兩個模型。

- 1D CNN 作為第一步模型
- Transformer 收尾

來看別人怎麼贏！

3. 解決影片長短不一

手語有的打很快，有的打很慢

- 訓練時：把所有影片截斷或補齊到 384 幀。
- 推論時：為了省時間，太長的資料直接截斷。
- 因果填補：在 CNN 中用來避免模型偷看未來資訊

來看別人怎麼贏！

4. 防止過擬合策略

因為模型是從頭訓練，而且訓練高達 400 輪，如果什麼都不做，AI 會過擬合

- 資料擴增
 - 時間上：隨機加速或放慢影片，或是隨機遮蔽某幾段時間。
 - 空間上：水平翻轉、隨機縮放、平移、旋轉、隨機挖空。
- 三大防禦機制
 - Drop Path (20%)
 - 極高的 Dropout (80%)
 - 加入權重雜訊 AWP (Adversarial Weight Perturbation)

來看別人怎麼贏！

5. Ensemble Learning 集成學習與訓練細節

透過上述設定，單一個模型就能達到 Public LB 0.80 的高分。

- 隨機種子集成

同一個模型，換了4 個不同的 Random Seed 與微調參數，重新訓練出 4個模型。最後取4 個的預測機率的平均，分數推升到 0.81 (Private 0.88)

- 優化器

使用了 RAdam + Lookahead 組合，並搭配 CosineDecay。

損失函數加入 Label Smoothing (0.1) 來避免模型過度自信。

排名怎麼差這麼大？！



- 參賽者在提交模型時為追求高分學習到了Public Leaderboard的特定分布而**對Private Test Set過擬和**，當切換到Private Leaderboard時模型的性能就會下滑。
- Public跟Private的Test Set差異可能有所影響，若兩者影片來源於演繹風格相差較多的人，模型泛化能力不足則會造成排名下滑。
- 本競賽**差異較小**的原因可能由於**兩個Leaderboard的指標各佔50%**，因此分布較為平均，不易出現樣本較小導致微小預測錯誤造成的分數大幅波動。



注意注意！！

I. 影片長度不同

- 每個人比手語速度不同
- 有些影片較短，有些較長
- 模型需要處理不同長度的時間序列資料

2. z 值不可靠

- 位置資訊 (x, y, z) 中的 z （離鏡頭遠近）的預測精度較低
- 多數方法主要使用平面座標，因為影片是平面
- z 值通常會被忽略或降低權重

注意注意！！

3. 人體關鍵點的偵測不完整

- 並非每個時間點都能偵測到手部
- 資料中可能存在缺失值或不完整的人體關鍵點

4. 手語表現差異

- 不同人使用左手或右手
- 動作速度與習慣不同
- 模型需學習通用特徵，而非記住個別使用者的動作

5. 硬體限制

- 模型檔案必須小於 40 MB
- 手機推論時間不能超過100毫秒，因此不能亂堆疊超大模型

該怎麼驗證呢？



- Hold-out跟K-Fold Cross驗證方法對於數據間相關性更高者有可能導致資料洩漏，因此用GroupKFold，以participant_id切分，可以**確保Validation裡的人對模型來說是陌生的**，符合Private Leaderboard的測試環境
- 因為手語單詞使用量分布有差異，可以用StratifiedGroupKFold讓**Fold中各類別的比例一致**，同一個人的數據不會跨Fold，這樣能讓預測表現更穩定，降低隨機性
- 牽扯到影像的時間長短序列的錯誤率是否一致，需要在預處理時進行更細緻的填充或採樣



小心！！有魔鬼！！

Devil #1 極度嚴苛的物理限制

- 推論時間： 每支影片的預測時間平均不能超過 100 毫秒（0.1秒）
- 模型大小： 模型檔案必須小於 40 MB

Devil #2 提交 TFLite 模型

- 一般的機器學習比賽，上傳一個 submission.csv（預測結果）就好。
- 這場比賽規定：把訓練好的模型轉換成 TensorFlow Lite 格式上傳！

小心！！有魔鬼！！

Devil #3 特徵工程必須「刻」進模型裡

- 官方給的推論程式碼輸入的資料是原始的座標矩陣。
- 所有的資料前處理都必須使用 TensorFlow 原生的 Tensor 運算，並把它們當作神經網路的「第一層」打包進去。

Devil #4 變動長度的時間序列

- 官方給的資料讀取程式碼的影格數是變動的。
- TFLite 模型必須能夠接受動態輸入大小，把所有輸入強制截斷或補零到固定長度，這在轉檔 TFLite 時又是一個很容易報錯的深水區。

Trouble Maker

使用 AI 生成完整模型

- 將題目說明與資料格式直接提供給 AI
 - 希望 AI 能直接生成完整訓練與提交程式
 - 模型雖然可以訓練，但 Kaggle 無法成功評分
- 遇到格式錯誤的問題

格式錯誤原因

- 輸入與輸出格式不符合規定
- TFLite 提交格式錯誤
- 訓練階段與推論階段的資料前處理方式不一致
- 模型輸出的資料格式不符合 Kaggle 要求
- 推論速度過慢導致繳交失敗

Nailed It!

Step 1. 建立基礎模型

- AI Prompt 重點
 - 說明比賽是 ASL 手語辨識
 - 說明輸入格式為 (n_frames, 543, 3)
 - 說明輸出為 250 類
 - 強調目標是「先成功 scoring」
 - 要求建立小型模型及簡單的資料前處理
 - 要求產生符合規範的 TFLite submission

Nailed It!

Step 1. 建立基礎模型

- 做法
 - 小型模型簡單 preprocessing
 - 少量訓練資料
- 結果
 - 雖然準確度很低，但成功得到 Kaggle score，表示格式正確
 - 準確率 = 0.008

Nailed It!

Step 2. 改善Data preprocessing以及model

- AI Prompt 重點
 - 只保留左右手、嘴唇與少量姿勢的關鍵點
 - 使用鼻子中心化座標
 - 加入輕量動態特徵
 - 使用 1D CNN + Transformer
 - 保持 TFLite 相容性
 - 避免推論太慢
 - 確保訓練時與實際推論的 preprocessing 一致

Nailed It!

Step 2. 改善Data preprocessing以及model

- 做法
 - 關鍵點只保留左手、右手、嘴唇、少量身體姿勢點
 - 以鼻子為中心的座標正規化
 - 使用 1D CNN + Transformer 結合的訓練模型
- 結果
 - 準確率從 0.008 $\rightarrow$ 0.54

Nailed It!

Step 3. 提升分數

- AI Prompt 重點
 - 訓練資料 2萬 → 4萬
 - 訓練 Epoch 20 → 40
 - 原本由左右手及嘴唇 → 左右手、嘴唇、眼角及 6 個 Pose
 - 序列長度 64 幀 → 80 幀+ 線性內插
 - 全資料集單一 Standard → 各樣本獨立 Robust Standard
 - 由隨機訓練 → 按照手語表演者分組

Nailed It!

Step 3. 提升分數

- 做法
 - 關鍵點保留左手、右手、嘴唇、眼角、身體姿勢
 - 在原模型上接 2 層 Transformer block 捕捉全局語意
- 結果
 - 準確率從 0.54 → 0.74

成發！！

最終成績在 Private Leaderboard 為 0.7433670；
在 Public Leaderboard 則為 0.6570489。
透過 AI 反覆調整模型訓練相比於最初結果具有顯著的預測效果提升。



1st place solution - inference - Version 5

Succeeded (after deadline) · 2d ago · Notebook 1st place solution - infere...

0.0087260

0.0117840



1st place solution - inference 3ebb74 - Version 1

Succeeded (after deadline) · 30m ago

0.7433670

0.6570489

